




MEDICAL COST PREDICTION

USING RANDOM FOREST REGRESSION

DEWI YULIANA



Introducing **ABOUT ME**

"Saya adalah mahasiswa fisika di Universitas Islam Negeri Sunan Gunung Djati Bandung yang mendalami fisika instrumentasi robotik dan metode komputasi. Dengan dasar yang kuat dalam Python, analisis data SQL, dan kecerdasan buatan, saya memiliki ketertarikan untuk menjembatani konsep teoretis dengan aplikasi di dunia nyata. Saya memiliki pengalaman langsung dalam AI, machine learning, dan pemrograman Python, serta terus mencari peluang untuk memperdalam pengetahuan saya di bidang data science."



-Dewi Yuliana



TOOLS USED




LIST OF CONTENTS

- 01** MACHINE LEARNING
- 02** RANDOM FOREST
REGRESSION
- 03** DATASET
- 04** LIBRARY
- 05** EDA
- 06** MODEL EVALUATION
- 07** PREDICTIONS

© 2006 The Authors
Journal compilation © 2006 Blackwell Publishing Ltd

Machine Learning adalah cabang kecerdasan buatan (AI) yang memungkinkan sistem untuk belajar dari data tanpa diprogram secara eksplisit. Dengan menggunakan algoritma statistik dan komputasi, machine learning mengidentifikasi pola dalam data untuk membuat prediksi atau keputusan secara otomatis. Teknik ini digunakan dalam berbagai bidang, seperti prediksi harga, deteksi anomali, pengenalan wajah, dan rekomendasi produk, dengan model yang terus diperbaiki seiring bertambahnya data yang diproses.



RANDOM FOREST

Random Forest adalah algoritma machine learning berbasis ensemble yang terdiri dari banyak decision tree untuk meningkatkan akurasi prediksi dan mengurangi overfitting. Dalam prosesnya, Random Forest membangun beberapa decision tree dari sampel acak dataset (bagging) dan menggabungkan hasil prediksi dari setiap pohon untuk mendapatkan keputusan akhir yang lebih stabil dan akurat. Algoritma ini dapat digunakan untuk tugas klasifikasi maupun regresi, serta dikenal karena ketahanannya terhadap outlier dan kemampuannya dalam menangani dataset dengan banyak fitur.



Ensemble Learning



Reduksi Overfitting




Bagging (Bootstrap Aggregating)

DATASET

- Sumber Dataset: Kaggle - Medical Cost Personal Dataset
- Jumlah Data: 1.300+ sampel
- Fitur Penting:
 - age (usia pasien)
 - bmi (indeks massa tubuh)
 - children (jumlah anak yang ditanggung asuransi)
 - smoker (status perokok)
 - region (lokasi pasien)
 - charges (biaya medis, target prediksi)



LIBRARY

A code editor window with a dark background. On the left, there is a play button icon. The code is written in a light-colored font. At the bottom right of the editor, there are two buttons: '+ Code' and '+ Text'.

```
# Import Library
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```


- pandas & numpy → Manipulasi dan analisis data.
- seaborn & matplotlib → Visualisasi data untuk EDA dan analisis fitur.
- sklearn.model_selection → Train-test split untuk membagi data sebelum pelatihan model.
- sklearn.preprocessing → One-Hot Encoding dan StandardScaler untuk menangani data kategorikal dan numerik.
- sklearn.ensemble.RandomForestRegressor → Model regresi berbasis Random Forest.
- sklearn.metrics → Evaluasi model menggunakan MAE, MSE, RMSE, dan R² Score

EDA

```
# Display data description  
data.describe()
```

```
# Exploratory Data Analysis (EDA)  
print(df.info())
```

- Exploratory Data Analysis (EDA) pada dataset Medical Cost Prediction dilakukan untuk memahami distribusi data, hubungan antar variabel, serta pola yang dapat memengaruhi biaya medis. Analisis ini mencakup pemeriksaan tipe data, deteksi nilai yang hilang, dan statistik ringkasan menggunakan `.info()` dan `.describe()`. Visualisasi seperti pairplot digunakan untuk melihat korelasi antar fitur, sementara one-hot encoding diterapkan pada variabel kategorikal seperti jenis kelamin, status perokok, dan wilayah. Selain itu, fitur numerik seperti usia, BMI, dan jumlah anak dinormalisasi menggunakan `StandardScaler` untuk memastikan skala yang seragam sebelum model machine learning diterapkan.



MODEL EVALUATION

Metric	Train	Test
MAE	2166.69	2447.87
MSE	15,681,758.05	19,040,272.98
R ²	0.8860	0.8899

- Exploratory Data Analysis (EDA) pada dataset Medical Cost Prediction dilakukan untuk memahami distribusi data, hubungan antar variabel, serta pola yang dapat memengaruhi biaya medis. Analisis ini mencakup pemeriksaan tipe data, deteksi nilai yang hilang, dan statistik ringkasan menggunakan `.info()` dan `.describe()`. Visualisasi seperti pairplot digunakan untuk melihat korelasi antar fitur, sementara one-hot encoding diterapkan pada variabel kategorikal seperti jenis kelamin, status perokok, dan wilayah. Selain itu, fitur numerik seperti usia, BMI, dan jumlah anak dinormalisasi menggunakan `StandardScaler` untuk memastikan skala yang seragam sebelum model machine learning diterapkan.

```
[ ] y_train_pred = model.predict(X_train)
    y_test_pred = model.predict(X_test)


[ ] train_mae = mean_absolute_error(y_train, y_train_pred)
    train_mse = mean_squared_error(y_train, y_train_pred)
    train_r2 = r2_score(y_train, y_train_pred)

[ ] test_mae = mean_absolute_error(y_test, y_test_pred)
    test_mse = mean_squared_error(y_test, y_test_pred)
    test_r2 = r2_score(y_test, y_test_pred)

[ ] print(f"Train MAE: {train_mae:.2f}")
    print(f"Train MSE: {train_mse:.2f}")
    print(f"Train R² Score: {train_r2:.4f}")


    print(f"Test MAE: {test_mae:.2f}")
    print(f"Test MSE: {test_mse:.2f}")
    print(f"Test R² Score: {test_r2:.4f}")
```

PREDICTIONS



Prediksi dalam konteks Medical Cost Prediction berarti menggunakan model machine learning untuk memperkirakan biaya medis seseorang berdasarkan fitur seperti usia, BMI, jumlah anak, status perokok, dan wilayah tempat tinggal. Model Random Forest Regressor yang telah dilatih pada data historis akan menerima input baru dan menghasilkan output berupa estimasi biaya medis. Setelah prediksi dilakukan, hasilnya dievaluasi menggunakan metrik seperti MAE, MSE, RMSE, dan R^2 Score untuk mengukur akurasi dan performa model. Semakin kecil error dan semakin tinggi nilai R^2 , semakin baik model dalam memprediksi biaya medis.

PREDICTIONS



Prediksi dalam konteks Medical Cost Prediction berarti menggunakan model machine learning untuk memperkirakan biaya medis seseorang berdasarkan fitur seperti usia, BMI, jumlah anak, status perokok, dan wilayah tempat tinggal. Model Random Forest Regressor yang telah dilatih pada data historis akan menerima input baru dan menghasilkan output berupa estimasi biaya medis. Setelah prediksi dilakukan, hasilnya dievaluasi menggunakan metrik seperti MAE, MSE, RMSE, dan R^2 Score untuk mengukur akurasi dan performa model. Semakin kecil error dan semakin tinggi nilai R^2 , semakin baik model dalam memprediksi biaya medis.

THANK YOU!



www.linkedin.com/in/dewiyuliana1507



<https://github.com/dewiyulianaa>



dewiyulianaa938@gmail.com